

# Series de Tiempo 2018

Maestría en Estadística Aplicada, UNR  
Unidad 3

---

Luis Damiano

[damiano.luis@gmail.com](mailto:damiano.luis@gmail.com)

2018-04-17

- Procesos autorregresivos.
- Procesos de media móvil.
- Procesos ARMA.

# Procesos autorregresivos

---

Proceso autorregresivo de primer orden  $AR(1)$

$$Z_t = \phi_1 Z_{t-1} + a_t, \quad t = 0, \pm 1, \dots$$

con  $a_t \sim \text{WN}(0, \sigma^2)$ ,  $|\phi_1| < 1$ , y  $a_t$  no está correlacionado con  $Z_s$  para todo  $s < t$  (Brockwell and Davis 2016, 15).

## Discusión en clases

¿Cómo simularían una muestra del proceso, dado el valor de los parámetros?

$$Z_t - \phi_1 Z_{t-1} = a_t, \quad t = 0, \pm 1, \dots, \quad a_t \sim \mathcal{N}(0, \sigma^2)$$

```
simAR1 <- function(phi1, sigma, Z0, T) {  
  TT <- 2 * T  
  
  # Ruido  
  at <- rnorm(TT, 0, sigma)  
  
  # Observaciones  
  Zt <- vector("numeric", TT)  
  Zt[1] <- Z0  
  for (t in 2:TT) {  
    Zt[t] <- phi1 * Zt[t - 1] + at[t]  
  }  
  
  # Descartamos la primera mitad para eliminar la influencia del valor inicial  
  tail(Zt, T)  
}
```



# Ejemplo

$$Z_t - 0.5Z_{t-1} = a_t, \quad t = 0, \pm 1, \dots, \quad a_t \sim \mathcal{N}(0, 1)$$


```
set.seed(9000)
z <- simAR1(-0.5, 1, 0, 100)

library(forecast)
fit <- Arima(
  z,
  order = c(1, 0, 0),
  include.mean = FALSE
)


lmfit <- lm(z[-1] ~ z[-length(z)] - 1)
```



Realización muestral de AR(1) con  $\phi_1 = 0.5$



Realización muestral de AR(1) con  $\phi_1 = 0.5$



## Ejercicio en clases

Analíticamente, encontrar la función de autocorrelación y la función de autocorrelación parcial.

# Modelo ajustado





```
## Series: z
## ARIMA(1,0,0) with zero mean
##
## Coefficients:
##          ar1
##        -0.4457
## s.e.    0.0896
##
## sigma^2 estimated as 0.8121:  log likelihood=-131.1
## AIC=266.19   AICc=266.32   BIC=271.4
```

## Discusión en clases

¿Cuáles son todos los supuestos del modelo? ¿Cómo validarían cada uno de ellos?



# Diagnóstico de residuos





¿Qué supuestos estamos diagnosticando? Hay un supuesto implícito que no estamos probando...

# Diagnóstico ¿predictivo?

Una forma diferente de diagnosticar el modelo: simular datos bajo el modelo ajustado y comparar estadísticos de resumen contra la muestra observada. ¿Qué decisiones hubiesen tomado con una muestra diferente?<sup>1</sup>

```
phiHat  <- coef(fit)
sigmaHat <- sd(residuals(fit))
genN    <- 500 # Generar genN muestras según modelo
genMin  <- vector("numeric", genN)
genMed  <- vector("numeric", genN)
genMax  <- vector("numeric", genN)
for (n in 1:genN) {
  gen <- simAR1(phiHat, sigmaHat, 0, length(z))
  genMin[n] <- min(gen)
  genMed[n] <- median(gen)
  genMax[n] <- max(gen)
}
gen      <- simAR1(phiHat, sigmaHat, 0, length(z))
```



<sup>1</sup>If the model fits, then replicated data generated under the model should look similar to observed data. [...] Any systematic differences between the simulations and the data indicate potential failings of the model (Gelman et al. 2014, p 143).

# Qué sucede si. . .


## Discusión en clases

¿Cuáles son las restricciones que se imponen sobre el coeficiente autorregresivo? ¿Qué imaginan que suceda si no se cumplen?


# Qué sucede si...

AR(1) siempre es invertible. Para que sea estacionario, se requiere que  $|\phi_1| < 1$ .


Realización muestral de AR(1) con  $\phi_1 = 1$




Realización muestral de AR(1) con  $\phi_1 = 1.5$



Realización muestral de AR(1) con  $\phi_1 = -1$



Realización muestral de AR(1) con  $\phi_1 = -1.5$



# Proceso autorregresivo de segundo orden

El siguiente es un proceso  $AR(2)$ :

$$Z_t - 1.3Z_{t-1} + 0.4Z_{t-2} = a_t, \quad t = 0, \pm 1, \dots, \quad a_t \sim \mathcal{N}(0, 1).$$

Para divertirse en casa:

- Escribir código para simular un conjunto de datos.
- Emplear `Arima` para estimar el valor de los parámetros y corroborar contra los valores prefijados.
- Emplear `Acf` para estimar las funciones ACF y PACF y corroborar con los resultados analíticos.
- Prueben de romper el modelo desafiando las condiciones de estacionariedad :)

# Procesos de medias móviles

---

Proceso de medias móviles de primer orden  $MA(1)$

$$Z_t = a_t - \theta_1 a_{t-1}, \quad t = 0, \pm 1, \dots$$

con  $a_t \sim \text{WN}(0, \sigma^2)$ ,  $\theta \in \mathbb{R}$  (Brockwell and Davis 2016, 15).

## Discusión en clases

¿Cómo simularían una muestra del proceso, dado el valor de los parámetros?

$$Z_t = a_t - \theta_1 a_{t-1}, \quad t = 0, \pm 1, \dots, \quad a_t \sim \mathcal{N}(0, \sigma^2)$$

```
simMA1 <- function(theta1, sigma, Z0, T) {  
  TT <- 2 * T  
  
  # Ruido  
  at <- rnorm(TT, 0, sigma)  
  
  # Observaciones  
  Zt <- vector("numeric", TT)  
  Zt[1] <- Z0  
  for (t in 2:TT) {  
    Zt[t] <- at[t] - theta1 * at[t - 1]  
  }  
  
  # Descartamos el primer 50%  
  tail(Zt, T)  
}
```




# Ejemplo


$$Z_t = a_t - 0.8a_{t-1}, \quad t = 0, \pm 1, \dots, \quad a_t \sim \mathcal{N}(0, 1)$$

```
set.seed(9000)
z <- simMA1(0.8, 1, 0, 100)


library(forecast)
fit <- Arima(
  z,
  order = c(0, 0, 1),
  include.mean = FALSE
)
```



Realización muestral de MA(1) con  $\theta_1 = 0.8$



Realización muestral de MA(1) con  $\theta_1 = 0.8$



## Ejercicio en clases

Analíticamente, encontrar la función de autocorrelación y la función de autocorrelación parcial.





# Modelo ajustado

```
## Series: z
## ARIMA(0,0,1) with zero mean
##
## Coefficients:
##          ma1
##        -0.8774
## s.e.    0.0805
##
## sigma^2 estimated as 0.8072:  log likelihood=-131.42
## AIC=266.83   AICc=266.96   BIC=272.04
```

## Discusión en clases

¿Cuáles son todos los supuestos del modelo? ¿Cómo validarían cada uno de ellos?

# Diagnóstico de residuos



El siguiente es un proceso  $MA(2)$ :

$$Z_t = a_t - 1.2a_{t-1} - 0.5a_{t-2}, \quad t = 0, \pm 1, \dots, \quad a_t \sim \mathcal{N}(0, 1)$$

Para divertirse en casa:

- Escribir código para simular un conjunto de datos.
- Emplear `Arima` para estimar el valor de los parámetros y corroborar contra los valores prefijados.
- Emplear `Acf` para estimar las funciones ACF y PACF y corroborar con los resultados analíticos.

# Procesos ARMA

---

Proceso  $ARMA$  de orden 1, 1

$$Z_t = \phi_1 Z_{t-1} + \theta_1 a_{t-1} + a_t, \quad t = 0, \pm 1, \dots$$

con  $a_t \sim \text{WN}(0, \sigma^2)$  y  $\phi_1 + \theta_1 \neq 0$  (Brockwell and Davis 2016, 48).

El proceso es estacionario si y sólo si  $\phi_1 \neq \pm 1$ .

Alternativamente,

$$\begin{aligned} Z_t - \phi_1 Z_{t-1} &= \theta_1 a_{t-1} + a_t \\ \phi(B)Z_t &= \theta(B)a_t. \end{aligned}$$

# Proceso ARMA( $p, q$ )

Proceso ARMA de orden  $p, q$

$$Z_t = \phi_1 Z_{t-1} + \cdots + \phi_p Z_{t-p} + \theta_1 a_{t-1} + \cdots + \theta_q a_{t-q} + a_t, \quad t = 0, \pm 1, \dots$$

con  $a_t \sim \text{WN}(0, \sigma^2)$ , y los polinomios característicos no tienen factores en común (Brockwell and Davis 2016, 74). El proceso es estacionario si y sólo si  $1 - \phi_1 Z - \cdots - \phi_p Z^p \neq 0$ .

Alternativamente,

$$\begin{aligned} Z_t - \phi_1 Z_{t-1} - \cdots - \phi_p Z_{t-p} &= \theta_1 a_{t-1} + \cdots + \theta_q a_{t-q} + a_t \\ \phi(B)Z_t &= \theta(B)a_t. \end{aligned}$$



## Proceso autorregresivo $ARMA(2, 1)$

El siguiente es un proceso  $ARMA(2, 1)$ :

$$(1 - 1.4B + 0.6B^2)Z_t = (1 - 0.8B)a_t, \quad t = 0, \pm 1, \dots, \quad a_t \sim \mathcal{N}(0, 1).$$

Para divertirse en casa:

- Emplear `arima.sim` para simular un conjunto de datos.
- Emplear `Arima` para estimar el valor de los parámetros y corroborar contra los valores prefijados.
- Emplear `Acf` para estimar las funciones ACF y PACF y corroborar con los resultados analíticos.

## Teoría

Para los modelos AR, MA, y ARMA:

- Especificación.
- Restricciones de los parámetros.
- Funciones de autocovariancia, autocorrelación, y autocorrelación parcial.
- Relación dual AR y MA.

## Tareas

Para los procesos AR(2), MA(2), y ARMA(2):

- Plantear el modelo.
- Explicitar (TODOS) los supuestos.
- Simular un conjunto de datos.
- Estimar estas cantidades en R.
- Encontrar analíticamente funciones de autocovariancia y autocorrelación.

## Discusión en clases

¿Preguntas, dudas, inquietudes, ansiedades, sugerencias?

# Anexo

---

# Algunas propiedades útiles

Sean  $X$  e  $Y$  variables aleatorias;  $k, a, b \in \mathbb{R}$  escalares constantes y finitos.

## Esperanza.

$$\mu = E\langle k \rangle = k \quad E\langle kX \rangle = k E\langle X \rangle \quad E\langle X + Y \rangle = E\langle X \rangle + E\langle Y \rangle \quad E\langle XY \rangle \neq E\langle X \rangle E\langle Y \rangle$$

## Varianza.

$$\sigma = V\langle X \rangle = E\langle (X - E\langle X \rangle)^2 \rangle = E\langle X^2 \rangle - E\langle X \rangle^2 \quad V\langle X \rangle \geq 0$$

$$V\langle X + k \rangle = V\langle X \rangle \quad V\langle kX \rangle = k^2 V\langle X \rangle \quad V\langle aX \pm bY \rangle = a^2 V\langle X \rangle + b^2 V\langle Y \rangle \pm 2ab \text{Cov}\langle X, Y \rangle$$

**Covarianza.** Como propiedad general, el operador de valor esperado no cumple con la propiedad multiplicativa. La diferencia está dada por la covarianza.

$$\gamma = \text{Cov}\langle X, Y \rangle = E\langle (X - E\langle X \rangle)(Y - E\langle Y \rangle) \rangle = E\langle XY \rangle - E\langle X \rangle E\langle Y \rangle \quad \text{Cov}\langle X, k \rangle = 0 \quad \text{Cov}\langle X, X \rangle = V\langle X \rangle$$

$$\text{Cov}\langle X, Y \rangle = \text{Cov}\langle Y, X \rangle \quad \text{Cov}\langle aX + bY \rangle = ab \text{Cov}\langle X, Y \rangle \quad \text{Cov}\langle X + a, Y + b \rangle = \text{Cov}\langle X, Y \rangle$$

## Correlación.

$$\rho = \text{Corr}\langle X, Y \rangle = \frac{\text{Cov}\langle X, Y \rangle}{\sqrt{V\langle X \rangle V\langle Y \rangle}} \text{ con } V\langle X \rangle \neq 0 \wedge V\langle Y \rangle \neq 0$$

Brockwell, Peter J., and Richard A. Davis. 2016. *Introduction to Time Series and Forecasting*. Springer International Publishing. doi:[10.1007/978-3-319-29854-2](https://doi.org/10.1007/978-3-319-29854-2).

Gelman, Andrew, John B Carlin, Hal S Stern, David B Dunson, Aki Vehtari, and Donald B Rubin. 2014. *Bayesian Data Analysis*. Vol. 2. CRC press Boca Raton, FL.