

Series de Tiempo 2018

Maestría en Estadística Aplicada, UNR
Unidad 9

Luis Damiano

damiano.luis@gmail.com

2018-05-10

- Modelos de suavizados exponenciales
- Cálculo de pronósticos
- Selección de modelos
- Ejercicio: Pasajeros en el subterráneo

Modelos de suavizados exponenciales (en diez minutos)

■ Elementos:

- \mathcal{T} Tendencia: Dirección de largo plazo.
- \mathcal{S} Estacionalidad: Patrón que se repite con una periodicidad conocida.
- \mathcal{C} Ciclo: Patrón que se repite con una periodicidad desconocida y cambiante.
- \mathcal{E} Irregular: Parte no predecible (también conocido como residuo, o error).

■ Combinación:

- \mathcal{N} Ninguno: El componente no existe o no es tenido en cuenta.
- \mathcal{A} Aditiva: Suma de componentes.
- \mathcal{M} Multiplicativa: Producto de componentes.
- Pueden aplicarse diferentes operadores para diferentes elementos.

¹Hyndman et al. (2008)

La tendencia T_h es una combinación de nivel ℓ y crecimiento b . $0 < \phi < 1$ es el parámetro de *damping*.

- Sin tendencia: $T_h = \ell$.
- Tendencia aditiva: $T_h = \ell + bh$.
- Tendencia aditiva con *damping*: $T_h = \ell + (\phi + \phi^2 + \dots + \phi^h)b$.
- Tendencia multiplicativa: $T_h = \ell b^h$.
- Tendencia multiplicativa con *damping*: $T_h = \ell b^{(\phi + \phi^2 + \dots + \phi^h)}$.

Damping: se cree improbable que la tasa de crecimiento observada hacia el final de la muestra se sostenga en el tiempo.

Suavizados exponenciales²

Trend component	Seasonal component		
	N (None)	A (Additive)	M (Multiplicative)
N (None)	N,N	N,A	N,M
A (Additive)	A,N	A,A	A,M
A _d (Additive damped)	A _d ,N	A _d ,A	A _d ,M
M (Multiplicative)	M,N	M,A	M,M
M _d (Multiplicative damped)	M _d ,N	M _d ,A	M _d ,M

- N, N: suavizado exponencial simple.
- A, N: modelo lineal de Holt.
- A, A: modelo aditivo de Holt-Winters.
- A, M: modelo multiplicativo de Holt-Winters.
- Que el error sea aditivo o multiplicativo no afecta los pronósticos puntuales.

²Hyndman et al. (2008)

Table 2.1. Formulae for recursive calculations and point forecasts.

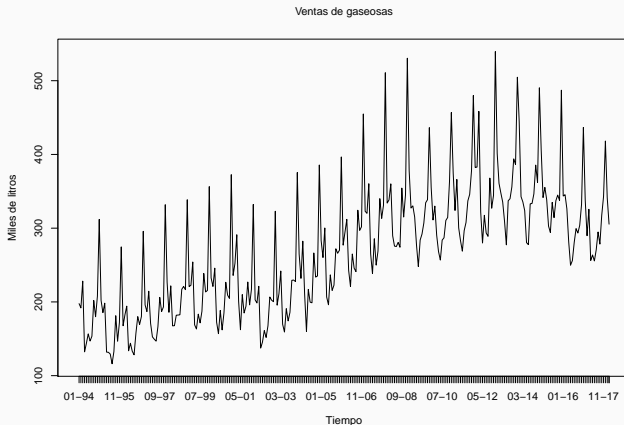
Trend	Seasonal		
	N	A	M
N	$\ell_t = \alpha y_t + (1 - \alpha)\ell_{t-1}$ $\hat{y}_{t+h t} = \ell_t$	$\ell_t = \alpha(y_t - s_{t-m}) + (1 - \alpha)\ell_{t-1}$ $s_t = \gamma(y_t - \ell_{t-1}) + (1 - \gamma)s_{t-m}$ $\hat{y}_{t+h t} = \ell_t + s_{t-m+h_m^+}$	$\ell_t = \alpha(y_t / s_{t-m}) + (1 - \alpha)\ell_{t-1}$ $s_t = \gamma(y_t / \ell_{t-1}) + (1 - \gamma)s_{t-m}$ $\hat{y}_{t+h t} = \ell_t s_{t-m+h_m^+}$
A	$\ell_t = \alpha y_t + (1 - \alpha)(\ell_{t-1} + b_{t-1})$ $b_t = \beta^*(\ell_t - \ell_{t-1}) + (1 - \beta^*)b_{t-1}$ $\hat{y}_{t+h t} = \ell_t + hb_t$	$\ell_t = \alpha(y_t - s_{t-m}) + (1 - \alpha)(\ell_{t-1} + b_{t-1})$ $b_t = \beta^*(\ell_t - \ell_{t-1}) + (1 - \beta^*)b_{t-1}$ $s_t = \gamma(y_t - \ell_{t-1} - b_{t-1}) + (1 - \gamma)s_{t-m}$ $\hat{y}_{t+h t} = \ell_t + hb_t + s_{t-m+h_m^+}$	$\ell_t = \alpha(y_t / s_{t-m}) + (1 - \alpha)(\ell_{t-1} + b_{t-1})$ $b_t = \beta^*(\ell_t - \ell_{t-1}) + (1 - \beta^*)b_{t-1}$ $s_t = \gamma(y_t / (\ell_{t-1} + b_{t-1})) + (1 - \gamma)s_{t-m}$ $\hat{y}_{t+h t} = (\ell_t + hb_t)s_{t-m+h_m^+}$
Ad	$\ell_t = \alpha y_t + (1 - \alpha)(\ell_{t-1} + \phi b_{t-1})$ $b_t = \beta^*(\ell_t - \ell_{t-1}) + (1 - \beta^*)\phi b_{t-1}$ $\hat{y}_{t+h t} = \ell_t + \phi b_t$	$\ell_t = \alpha(y_t - s_{t-m}) + (1 - \alpha)(\ell_{t-1} + \phi b_{t-1})$ $b_t = \beta^*(\ell_t - \ell_{t-1}) + (1 - \beta^*)\phi b_{t-1}$ $s_t = \gamma(y_t - \ell_{t-1} - \phi b_{t-1}) + (1 - \gamma)s_{t-m}$ $\hat{y}_{t+h t} = \ell_t + \phi b_t + s_{t-m+h_m^+}$	$\ell_t = \alpha(y_t / s_{t-m}) + (1 - \alpha)(\ell_{t-1} + \phi b_{t-1})$ $b_t = \beta^*(\ell_t - \ell_{t-1}) + (1 - \beta^*)\phi b_{t-1}$ $s_t = \gamma(y_t / (\ell_{t-1} + \phi b_{t-1})) + (1 - \gamma)s_{t-m}$ $\hat{y}_{t+h t} = (\ell_t + \phi b_t)s_{t-m+h_m^+}$
M	$\ell_t = \alpha y_t + (1 - \alpha)\ell_{t-1}b_{t-1}$ $b_t = \beta^*(\ell_t / \ell_{t-1}) + (1 - \beta^*)b_{t-1}$ $\hat{y}_{t+h t} = \ell_t b_t^h$	$\ell_t = \alpha(y_t - s_{t-m}) + (1 - \alpha)\ell_{t-1}b_{t-1}$ $b_t = \beta^*(\ell_t / \ell_{t-1}) + (1 - \beta^*)b_{t-1}$ $s_t = \gamma(y_t - \ell_{t-1}b_{t-1}) + (1 - \gamma)s_{t-m}$ $\hat{y}_{t+h t} = \ell_t b_t^h + s_{t-m+h_m^+}$	$\ell_t = \alpha(y_t / s_{t-m}) + (1 - \alpha)\ell_{t-1}b_{t-1}$ $b_t = \beta^*(\ell_t / \ell_{t-1}) + (1 - \beta^*)b_{t-1}$ $s_t = \gamma(y_t / (\ell_{t-1}b_{t-1})) + (1 - \gamma)s_{t-m}$ $\hat{y}_{t+h t} = \ell_t b_t^h s_{t-m+h_m^+}$
M _d	$\ell_t = \alpha y_t + (1 - \alpha)\ell_{t-1}b_{t-1}^\phi$ $b_t = \beta^*(\ell_t / \ell_{t-1}) + (1 - \beta^*)b_{t-1}^\phi$ $\hat{y}_{t+h t} = \ell_t b_t^{\phi h}$	$\ell_t = \alpha(y_t - s_{t-m}) + (1 - \alpha)\ell_{t-1}b_{t-1}^\phi$ $b_t = \beta^*(\ell_t / \ell_{t-1}) + (1 - \beta^*)b_{t-1}^\phi$ $s_t = \gamma(y_t - \ell_{t-1}b_{t-1}^\phi) + (1 - \gamma)s_{t-m}$ $\hat{y}_{t+h t} = \ell_t b_t^{\phi h} + s_{t-m+h_m^+}$	$\ell_t = \alpha(y_t / s_{t-m}) + (1 - \alpha)\ell_{t-1}b_{t-1}^\phi$ $b_t = \beta^*(\ell_t / \ell_{t-1}) + (1 - \beta^*)b_{t-1}^\phi$ $s_t = \gamma(y_t / (\ell_{t-1}b_{t-1}^\phi)) + (1 - \gamma)s_{t-m}$ $\hat{y}_{t+h t} = \ell_t b_t^{\phi h} s_{t-m+h_m^+}$

In each case, ℓ_t denotes the series level at time t , b_t denotes the slope at time t , s_t denotes the seasonal component of the series at time t , and m denotes the number of seasons in a year; α, β^*, γ and ϕ are constants, $\phi_h = \phi + \phi^2 + \dots + \phi^h$ and $h_m^+ = [(h - 1) \bmod m] + 1$.

³Hyndman et al. (2008)

Pronósticos

Ejemplo



Discusión en clases

¿Qué familia de modelos ajustarían? ¿Qué características creen importante modelar a los fines del pronóstico?


```
fit <- ets(z_ts, lambda = 0)
fit
```

```
## ETS(A,N,A)
##
## Call:
## ets(y = z_ts, lambda = 0)
##
## Box-Cox transformation: lambda= 0
##
## Smoothing parameters:
##   alpha = 0.3129
##   gamma = 0.2898
##
## Initial states:
##   l = 5.1893
##   s=0.5302 0.0586 -0.0399 0.0803 -0.169 -0.2345
##        -0.1682 -0.2037 -0.2181 0.1915 0.0791 0.0937
##
## sigma: 0.0673
##
##      AIC      AICc      BIC
## 108.9043 110.6562 163.9525
```

```
fore <- forecast(fit, h = 12)
fore
```

##	Point Forecast	Lo 80	Hi 80	Lo 95	Hi 95
## Mar 2018	321.1967	294.6628	350.1200	281.5157	366.4710
## Apr 2018	276.9278	253.0060	303.1114	241.1908	317.9600
## May 2018	260.1531	236.7454	285.8752	225.2191	300.5057
## Jun 2018	255.8459	231.9466	282.2078	220.2125	297.2453
## Jul 2018	279.7718	252.7153	309.7250	239.4683	326.8585
## Aug 2018	287.6792	258.9458	319.6009	244.9159	337.9091
## Sep 2018	291.4730	261.4695	324.9195	246.8578	344.1517
## Oct 2018	313.8912	280.6525	351.0664	264.5064	372.4963
## Nov 2018	326.2855	290.8009	366.1001	273.6064	389.1073
## Dec 2018	429.2116	381.3426	483.0896	358.2028	514.2970
## Jan 2019	341.0774	302.1185	385.0600	283.3300	410.5945
## Feb 2019	305.3752	267.6260	348.4490	249.5701	373.6586

Pronóstico del modelo ETS(A, N, A)



Evaluación de pronósticos

Comparar la precisión de diferentes modelos conforma una de las etapas más importantes del proceso de pronóstico.

- Elección de la variable a pronosticar.
- Métrica del error de pronóstico que resulta más relevante para el proceso de selección. Forma de penalizar de pronósticos sub y sobre estimados.
- Criterio de selección de un modelo superior en términos de pronósticos, en especial dado que el error de pronóstico es una variable aleatoria en sí misma.
- Tratamiento de la correlación en el error de pronóstico cuando los parámetros son estimados a partir de conjuntos de datos solapados.

- Idealmente, el proceso de evaluación de pronósticos debe reflejar la utilidad que éstos tienen para el analista.
- Sin embargo, ello requiere un conocimiento preciso del proceso de decisión, incluyendo las funciones de costo y beneficio.
- En consecuencia, casi la totalidad de los trabajos científicos se limitan a aplicar métricas estadísticas.

$$ME = \frac{1}{T} \sum_{t=1}^T (\hat{Z}_t - Z_t)$$

- Mide el desvío promedio.
- Conserva la dirección de los errores, por lo cual también se lo considera una medida del sesgo.
- Dado que las diferencias positivas y negativas pueden cancelarse, cero no indica pronósticos perfectos sino la inexistencia de sesgos.
- Dependiente de la escala de medición y la transformación aplicada.
- Todos los errores son penalizados equitativamente.
- Los valores deseables son cercanos a cero.

$$\text{MSE} = \frac{1}{T} \sum_{t=1}^T \left(\hat{Z}_t - Z_t \right)^2$$

- Los errores con signo contrario no se cancelan, de forma que el estadístico presenta una medida global del error de pronóstico pero no indica su dirección.
- Al ser una función cuadrática, penaliza los errores más extremos y enfatiza que el error total de pronóstico está afectado ampliamente por las grandes diferencias individuales.
- Depende de la escala de medición y la transformación aplicada.
- Su relación con el núcleo de la densidad gaussiana la convierte en una medida útil a pesar de ser poco intuitiva y difícil de interpretar.
- Esta función de pérdida depende del error de pronóstico, el cual está aproximadamente centrado en cero y tiene una variancia proporcional al cuadrado de la variancia de la variable original.
- Estimador sensible a observaciones extremas.

$$\text{RMSE} = \sqrt{\frac{1}{T} \sum_{t=1}^T (\hat{Z}_t - Z_t)^2}$$

- La medición se realiza en la misma unidad que la variable de interés, facilitando su interpretación.

$$\text{LMSE} = \frac{1}{T} \sum_{t=1}^T (\ln \hat{Z}_t - \ln Z_t)^2.$$

- Uso de la función logarítmica para disminuir el efecto de valores extremos.

$$\text{MAE} = \frac{1}{T} \sum_{t=1}^T |\hat{Z}_t - Z_t|$$

- También conocido como desvío absoluto medio.
- Medida de la magnitud global del error de pronóstico.
- No provee información de la dirección del error pues las diferencias de signo contrario no se cancelan.
- Penaliza todos los errores en proporción a su magnitud.
- Depende de la escala de medición y la transformación aplicada.
- Los valores deseables son cercanos a cero.

$$\text{MAPE} = \frac{1}{T} \sum_{t=1}^T \frac{|\hat{Z}_t - Z_t|}{Z_t}$$

- Medida relativa.
- Independiente de la escala de medición.
- Afectada por la transformación de los datos.
- No revela información sobre el signo del error.
- Penaliza las diferencias de forma proporcional.

Las razones de acierto miden la habilidad del pronóstico para anticipar cambios direccionales.

Sean T^+ y T^- la cantidad total de incrementos y decrementos del período fuera de la muestra.

$$\text{Hit}^+ = \frac{1}{T^+} \sum_{t=1} T^+ \mathbb{I}_{\left((\hat{Z}-Z_t)(Z_{t+1}-Z_t)>0\right)} \times \mathbb{I}_{(Z_{t+1}-Z_t>0)}$$

$$\text{Hit}^- = \frac{1}{T^-} \sum_{t=1} T^- \mathbb{I}_{\left((\hat{Z}-Z_t)(Z_{t+1}-Z_t)>0\right)} \times \mathbb{I}_{(Z_{t+1}-Z_t<0)}.$$

$$\text{MCPDC} = \frac{1}{T} \left(T^+ \text{Hit}^+ + T^- \text{Hit}^- \right).$$

Rolling Window




Figure 1: [Ver online.](#)

Rolling forecast: Paso 1/3

Crear una función para producir un pronóstico dado una muestra llamada x .

```
fore1 <- function(x) {  
  x_ts <- ts(as.numeric(x), frequency = 12)  
  
  # 1. Ajustar  
  fit <- ets(x_ts, lambda = 0)  
  
  # 2. Pronosticar  
  fore <- forecast(fit, h = 1)  
  
  # 3. Devolver  
  c(fore$lower[2], fore$mean, fore$upper[2])  
}  
  
fore1(z["1994/2010"])  
  
## [1] 309.1739 352.1758 401.1587
```

Rolling forecast: Paso 2/3

Correr la función para submuestra de tamaño $w = 120$ (diez años).

```
w      <- 120 # w ancho de ventana
z_hat1 <- rollapplyr(z, width = w, FUN = fore1)

tail(z_hat1)
```

```
##           [,1]      [,2]      [,3]
## 2017-09-01 273.1190 306.8248 344.6902
## 2017-10-01 289.1750 324.7741 364.7555
## 2017-11-01 405.9536 455.7448 511.6431
## 2017-12-01 307.0735 344.6692 386.8679
## 2018-01-01 273.0866 305.7888 342.4070
## 2018-02-01 286.7721 321.4350 360.2877
```


Rolling forecast: Paso 3/3

Alinear observación real y pronóstico (generado en el período inmediato anterior).

```
z_all1 <- cbind(z, lag(z_hat1, 1))  
colnames(z_all1) <- c("Real", "Inferior", "Medio", "Superior")  
  
tail(z_all1)
```

```
##           Real Inferior    Medio Superior  
## 2017-09-01 278.419 275.0545 308.4881 345.9857  
## 2017-10-01 317.422 273.1190 306.8248 344.6902  
## 2017-11-01 343.126 289.1750 324.7741 364.7555  
## 2017-12-01 418.192 405.9536 455.7448 511.6431  
## 2018-01-01 341.398 307.0735 344.6692 386.8679  
## 2018-02-01 305.445 273.0866 305.7888 342.4070
```

Ejemplo

Ventas de gaseosas

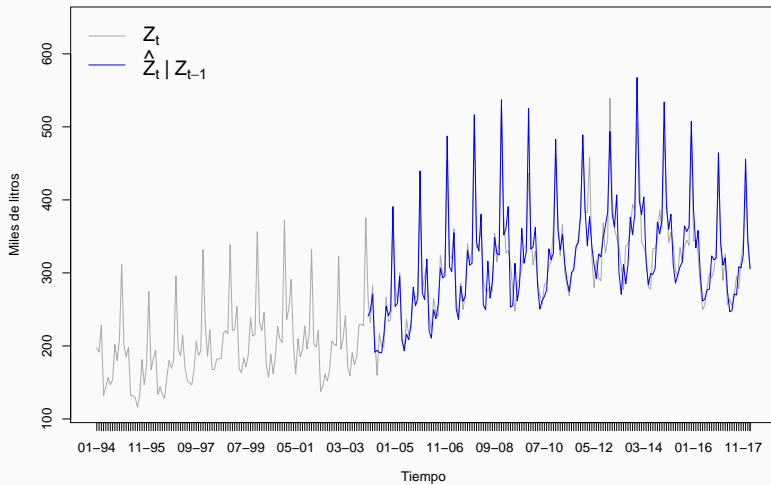



FIGURE 1-1. The Prediction-Realization Diagram





⁴Ver online.

Ejemplo

```
lmfit <- lm(
  Real ~ Medio,
  data = as.data.frame(z_all1)
)
summary(lmfit)

##
## Call:
## lm(formula = Real ~ Medio, data = as.data.frame(z_all1))
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -65.083 -15.228   0.397  13.996  90.608
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  44.90373     8.38110   5.358 2.74e-07 ***
## Medio        0.85649     0.02558  33.486 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 23.98 on 168 degrees of freedom
## (120 observations deleted due to missingness)
## Multiple R-squared:  0.8697, Adjusted R-squared:  0.8689
## F-statistic: 1121 on 1 and 168 DF, p-value: < 2.2e-16
```

Ventas de gaseosas



Ejercicio: Pasajeros en el subterráneo

Ejercicio en clases

Calcular y análisis los pronósticos de la serie de tiempo de ejemplo.

Solución disponible en el anexo.

Algunos pasos:

- Descargar los datos desde <https://bit.ly/2GXzXoa>.
- De la Sección A 1.10, leer los datos mensuales para la columna *Pasaj. Serv. subterráneos Metrovías SA*.⁵
- Graficar y describir la serie original. ¿Qué características de la serie parece importante modelar a la hora de pronosticar?
- Proponer un modelo de la familia ARIMA y un modelo de suavizado exponencial.
- Evaluar los pronósticos fuera de la muestra.
- ¿Cómo evaluarían cuál es mejor? Antes que eso... ¿qué entienden por "mejor"?

⁵ Hay una copia local en `data/METROPasajeros.txt` en caso de que el sitio esté fuera de línea.

Anexo: Pasajeros en el subterráneo

Lectura & procesamiento

```
# https://bit.ly/2GXzXoa
df <- read.table(
  file = "data/METROPasajeros.txt",
  header = TRUE,
  sep = "\t",
  dec = ",",
)


df[, 1] <- as.Date(df[, 1], format = "%Y-%m-%d")

z <- xts(x = df[, 2] / 1000, order.by = df[, 1])
z_ts <- ts(z, frequency = 12) # stl requiere un objeto del tipo ts


t(head(z, 9))

## 1993-01-01 1993-02-01 1993-03-01 1993-04-01 1993-05-01 1993-06-01
## x      8.521      9.014      12.311      10.683      12.078      12.755
## 1993-07-01 1993-08-01 1993-09-01
## x      13.254      13.197      13.842
```


Pasajeros en el subterráneo




Serie transformada (ln)



Primera diferencia de la serie transformada (ln)



Primera dif. principal y estacional de la serie transformada (ln)



Ajuste (1)

```
fore1 <- function(x) {  
  # 1. Ajustar  
  fit <- Arima(  
    x,  
    order = c(1, 1, 0),  
    seasonal = list(order = c(0, 1, 1), period = 12),  
    include.mean = FALSE,  
    include.drift = FALSE,  
    lambda = 0  
  )  
  
  # 2. Pronosticar  
  fore <- forecast(fit, h = 1)  
  
  # 3. Devolver  
  c(fore$lower[2], fore$mean, fore$upper[2])  
}
```

Ajuste (2)

```
fore2 <- function(x) {  
  # 1. Ajustar  
  fit <- Arima(  
    x,  
    order = c(1, 1, 0),  
    seasonal = list(order = c(2, 1, 0), period = 12),  
    include.mean = FALSE,  
    include.drift = FALSE,  
    lambda = 0  
  )  
  
  # 2. Pronosticar  
  fore <- forecast(fit, h = 1)  
  
  # 3. Devolver  
  c(fore$lower[2], fore$mean, fore$upper[2])  
}
```

Ajuste (3)

```
fore3 <- function(x) {  
  x_ts <- ts(as.numeric(x), frequency = 12)  
  
  # 1. Ajustar  
  fit <- ets(x_ts, model = "MAM") # Holt-Winters Multiplicativo  
  
  # 2. Pronosticar  
  fore <- forecast(fit, h = 1)  
  
  # 3. Devolver  
  c(fore$lower[2], fore$mean, fore$upper[2])  
}
```

Pronósticos

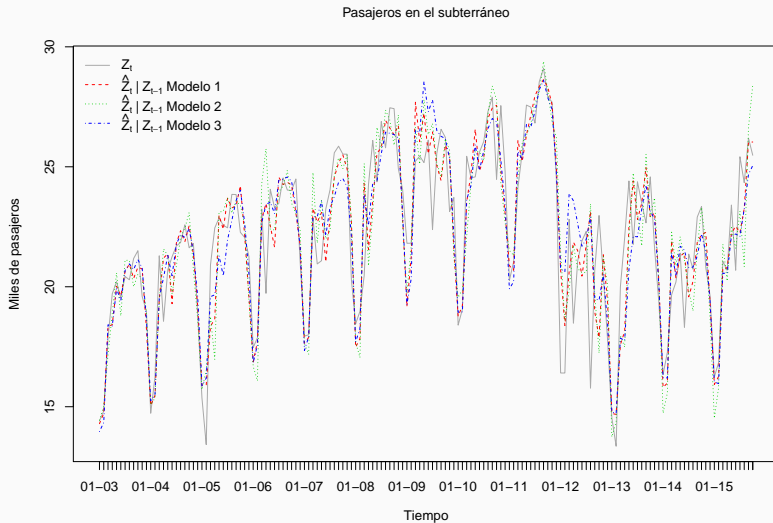
```
w      <- 120 # w ancho de ventana
z_hat1 <- rollapplyr(z, width = w, FUN = fore1)
z_hat2 <- rollapplyr(z, width = w, FUN = fore2)
z_hat3 <- rollapplyr(z, width = w, FUN = fore3)

z_all1 <- cbind(z, lag(z_hat1[, 2], 1), lag(z_hat2[, 2], 1), lag(z_hat3[, 2], 1))
z_all1 <- na.omit(z_all1)
colnames(z_all1) <- c("Real", "Modelo 1", "Modelo 2", "Modelo 3")

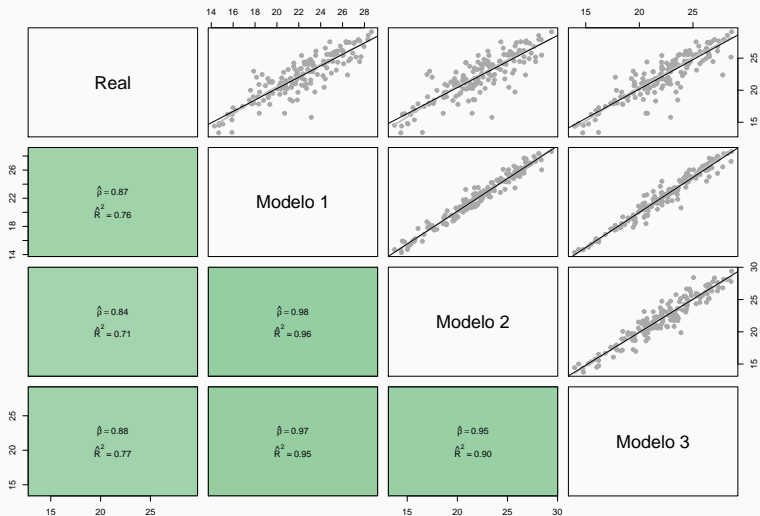
tail(z_all1)
```

```
##           Real Modelo 1 Modelo 2 Modelo 3
## 2015-05-01 23.406 22.22269 22.46286 22.11499
## 2015-06-01 20.689 22.52518 21.59970 22.20012
## 2015-07-01 25.419 22.24907 23.15162 22.09608
## 2015-08-01 24.337 23.25208 20.83735 23.24763
## 2015-09-01 26.194 26.02481 26.63670 24.67929
## 2015-10-01 25.480 26.03304 28.41701 25.05414
```

Pronóstico versus observado (1)



Pronóstico versus observado (2)



Selección de modelo (dentro de la muestra)

```
fit1 <- Arima(z,
  order = c(1, 1, 0),
  seasonal = list(order = c(0, 1, 1), period = 12),
  include.mean = FALSE, include.drift = FALSE,
  lambda = 0
)
fit2 <- Arima(z,
  order = c(1, 1, 0),
  seasonal = list(order = c(2, 0, 0), period = 12),
  include.mean = FALSE, include.drift = FALSE,
  lambda = 0
)
fit3 <- ets(z_ts, model = "MAM")
cbind(
  SD = sqrt(c(fit1$sigma2, fit2$sigma2, fit3$sigma2)),
  AIC(fit1, fit2, fit3),
  BIC(fit1, fit2, fit3),
  AICc = c(fit1$aicc, fit2$aicc, fit3$aicc)
)
```

	##		SD	df		AIC	df		BIC		AICc
##	fit1	0.06646780	3	-632.8192	3	-622.1256	-632.7258				
##	fit2	0.08087444	4	-580.3708	4	-565.9329	-580.2215				
##	fit3	0.05771749	18	1648.5355	18	1713.5719	1651.2179				

Selección de modelo (fuera de la muestra)

```
MSE <- function(fore, real) { mean((fore - real)^2) }  
RMSE <- function(fore, real) { sqrt(MSE(fore, real)) }  
MAE <- function(fore, real) { mean(abs(fore - real)) }  
MAPE <- function(fore, real) { mean(abs(fore - real) / real) }  
MZR2 <- function(fore, real) { summary(lm(real ~ fore))$r.squared }  
MSE(z_all1[, 2], z_all1[, 1]) # Modelo 1 (columna 2) vs. real (columna 1)
```

```
## [1] 2.912193
```

```
RMSE(z_all1[, 2], z_all1[, 1])
```

```
## [1] 1.706515
```

```
MAE(z_all1[, 2], z_all1[, 1])
```

```
## [1] 1.264192
```

```
MAPE(z_all1[, 2], z_all1[, 1])
```

```
## [1] 0.05929207
```

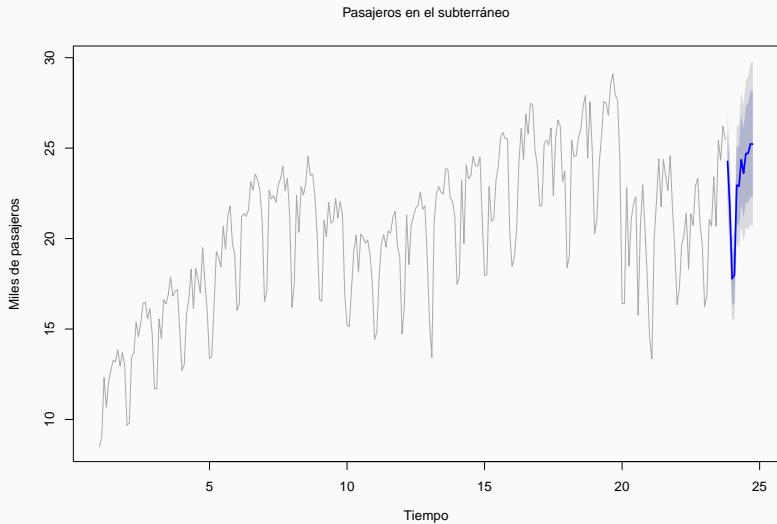
```
MZR2(z_all1[, 2], z_all1[, 1])
```

```
## [1] 0.7621423
```

Selección de modelo

	SD	AIC	BIC	AICc	MSE	RMSE	MAE	MAPE	MZR2
Modelo 1	0.07	-632.82	-622.13	-632.73	2.91	1.71	1.26	5.93	0.76
Modelo 2	0.08	-580.37	-565.93	-580.22	3.86	1.96	1.47	6.95	0.71
Modelo 3	0.06	1648.54	1713.57	1651.22	2.74	1.65	1.18	5.60	0.77

Modelo seleccionado



Hyndman, Rob, Anne Koehler, Keith Ord, and Ralph Snyder. 2008. *Forecasting with Exponential Smoothing*. Springer Berlin Heidelberg. doi:[10.1007/978-3-540-71918-2](https://doi.org/10.1007/978-3-540-71918-2).